5. ESTIMATION PAR INTERVALLE DE CONFIANCE

Après avoir donné la définition d'un intervalle de confiance et présenté ses propriétés, ce chapitre expose les principes de construction de tels intervalles.

5.1. Estimateur par intervalle de confiance et ses propriétés

La définition d'un estimateur par intervalle de confiance est donnée en premier et ses propriétés sont présentées dans la suite.

5.1.1. Définition d'un estimateur par intervalle de confiance

DEFINITION : *Un estimateur par intervalle de confiance pour le paramètre réel inconnu θ, de niveau de confiance $(1-\alpha)$, est un intervalle*

$$IC(X_1,\ldots,X_n)=\left[A_n(X_1,\ldots,X_n),B_n(X_1,\ldots,X_n)\right]$$

à valeur dans l'ensemble des parties de $\Theta=\mathbb{R}$ ($\mathcal{P}(\Theta)$), noté $IC(\theta)$ et vérifiant la condition suivante :

$$\forall\theta\in\Theta,\quad P_\theta\left(\theta\in IC(X_1,\ldots,X_n)\right)=P_\theta\left(\theta\in IC(\theta)\right)=1-\alpha$$

où $A_n(X_1,\ldots,X_n)$ et $B_n(X_1,\ldots,X_n)$ sont ses extrémités aléatoires définies sur $\mathcal{X}^n$ à valeurs dans Θ.

Remarques

- Les extrémités $A_n(X_1,\ldots,X_n)$ et $B_n(X_1,\ldots,X_n)$ de l'intervalle de confiance $IC(\theta)$ sont des statistiques et donc varient d'un échantillon à l'autre ;
- Le taux d'erreur α est fixé par l'expérimentateur avant d'observer les données $\{x_1,\ldots,x_1\}$ issues de l'observation du phénomène étudié, il s'exprime généralement en pourcentage et ses valeurs usuelles sont 1%, 5% ou 10% ;

Exemple 5.1. *: Soit l'intervalle de confiance $I=[50,56]$ de niveau de confiance 90% pour θ. Donner une interprétation fréquentiste et bayésienne de I.*

DEFINITION : *Un estimateur par région de confiance pour le paramètre vectoriel inconnu θ, de niveau de confiance $(1-\alpha)$, est une région*

$$\delta(X_1,\ldots,X_n)=\left[A_n(X_1,\ldots,X_n),B_n(X_1,\ldots,X_n)\right]$$

à valeur dans l'ensemble des parties de $\Theta=\mathbb{R}^m$ ($\mathcal{P}(\Theta)$), noté $IC(\theta)$ et vérifiant la condition :

$$\inf_{\theta\in\Theta}P_\theta\left(\theta\in\delta(X_1,\ldots,X_n)\right)=\inf_{\theta\in\Theta}P_\theta\left(\theta\in IC(\theta)\right)=1-\alpha$$

où $A_n(X_1,\ldots,X_n)$ et $B_n(X_1,\ldots,X_n)$ sont ses extrémités aléatoires définies sur $\mathcal{X}^n$ à valeurs dans Θ.

5.1.2. Différents types d'intervalles de confiance

DEFINITION : *Un intervalle de confiance bilatéral pour le paramètre inconnu θ de niveau de confiance $(1-\alpha)$, est un intervalle*

$$IC(X_1,\ldots,X_n)=\left[A_n(X_1,\ldots,X_n),B_n(X_1,\ldots,X_n)\right]$$

à valeur dans l'ensemble des parties de $\Theta=\mathbb{R}$ ($\mathcal{P}(\Theta)$), noté $IC(\theta)$ et vérifiant la condition :

$$\forall\theta\in\Theta,\quad P_\theta\left(\theta\in IC(X_1,\ldots,X_n)\right)=P_\theta\left(\theta\in IC(\theta)\right)=1-\alpha$$

où $A_n(X_1,\ldots,X_n)$ et $B_n(X_1,\ldots,X_n)$ sont ses extrémités aléatoires définies sur $\mathcal{X}^n$ à valeurs dans Θ et différentes de l'infini.

Exemple 5.2. *: Soit $\{X_1,\ldots,X_n\}$ un échantillon théorique issu d'une loi gaussienne de moyenne θ inconnue et de variance σ_0^2 connue. Sur la base du résultat,*

$$\frac{\sqrt{n}\left(\bar{X}_n-\theta\right)}{\sigma_0}\sim\mathcal{N}(0,1)$$

Construire un intervalle de confiance bilatéral de niveau $(1-\alpha)$ pour θ.

DEFINITION : *Un intervalle de confiance unilatéral à gauche pour le paramètre inconnu θ de niveau de confiance $(1-\alpha)$, est un intervalle*

$$IC(X_1,\ldots,X_n)=\left]-\infty,B_n(X_1,\ldots,X_n)\right]$$

à valeur dans l'ensemble des parties de $\Theta=\mathbb{R}$ ($\mathcal{P}(\Theta)$), noté $IC(\theta)$ et vérifiant :

$$\forall\theta\in\Theta,\quad P_\theta\left(\theta\in IC(X_1,\ldots,X_n)\right)=P_\theta\left(\theta\in IC(\theta)\right)=1-\alpha$$

où son extrémité supérieure $B_n(X_1,\ldots,X_n)$ est aléatoires, définies sur $\mathcal{X}^n$ à valeurs dans Θ et différente de l'infini.

DEFINITION : *Un intervalle de confiance unilatéral à droite pour le paramètre inconnu θ de niveau de confiance $(1-\alpha)$, est un intervalle*

$$IC(X_1,\ldots,X_n)=\left[A_n(X_1,\ldots,X_n),+\infty\right[$$

à valeur dans l'ensemble des parties de $\Theta=\mathbb{R}$ ($\mathcal{P}(\Theta)$), noté $IC(\theta)$ et vérifiant :

$$\forall\theta\in\Theta,\quad P_\theta\left(\theta\in IC(X_1,\ldots,X_n)\right)=P_\theta\left(\theta\in IC(\theta)\right)=1-\alpha$$

où son extrémité inférieure $A_n(X_1,\ldots,X_n)$ est aléatoires, définie sur $\mathcal{X}^n$ à valeurs dans Θ et différente de l'infini.

Exemple 5.3. *: Reprendre l'exercice 5.2. Construire les intervalles de confiance unilatéraux de niveau $(1-\alpha)$ pour θ.*

DEFINITION : *Un intervalle de confiance asymptotique pour le paramètre inconnu θ de niveau de confiance $(1-\alpha)$, est un intervalle*

$$IC(X_1,\ldots,X_n)=\left[A_n(X_1,\ldots,X_n),B_n(X_1,\ldots,X_n)\right]$$

à valeur dans l'ensemble des parties de $\Theta=\mathbb{R}$ ($\mathcal{P}(\Theta)$), noté $IC(\theta)$ et vérifiant :

$$\forall\theta\in\Theta,\quad \lim_{n\to+\infty}P_\theta\left(\theta\in IC(X_1,\ldots,X_n)\right)=1-\alpha$$

où $A_n(X_1,\ldots,X_n)$ et $B_n(X_1,\ldots,X_n)$ sont ses extrémités aléatoires définies sur $\mathcal{X}^n$ à valeurs dans Θ.

5.1.3. Propriétés désirables d'un intervalle de confiance

5.1.3.1. Propriété sans biais

DEFINITION : *Un intervalle de confiance $IC(\theta)$ de niveau $(1-\alpha)$ pour le paramètre inconnu θ est dit sans biais si la probabilité qu'il recouvre la bonne valeur de θ est supérieure à la probabilité qu'il recouvre une valeur erronée θ^**

5.1.4.2. Autres propriétés désirables d'un intervalle de confiance

Les autres propriétés désirables d'un intervalle sont sa précision (longueur de l'intervalle) et sa sureté (taux de recouvrement des valeurs erronées petit).

DEFINITION : *Un intervalle de confiance $IC(\theta)$ de niveau $(1-\alpha)$ pour le paramètre inconnu θ. La marge d'erreur ou erreur d'Estimation Maximale à un niveau de confiance $(1-\alpha)$, notée* EEM*, est la demi longueur de l'intervalle de confiance.*

Par exemple, pour l'intervalle de confiance de la moyenne θ utilisé précédemment,

$$IC(\theta)=\hat{\theta}\pm z_{1-\alpha/2}\sqrt{\frac{\sigma_0^2}{n}}=\hat{\theta}\pm EEM=\left[\hat{\theta}-EEM,\hat{\theta}+EEM\right]$$

5.2. Comparaison d'estimateurs par intervalles de confiance

5.2.1. Définition de la fonction de risque

DÉFINITION : *Soit $IC(\theta)$ un intervalle de confiance de niveau $(1-\alpha)$ pour le paramètre inconnu θ. Une fonction de risque (ou fonction de risque fréquentiste) de $IC(\theta)$ associée à la fonction de perte 0-1 $\mathcal{L}$ est la fonction, notée R, définie de Θ vers $\mathbb{R}^+$ par :*

$$R(\theta,\delta)=P_\theta\left(\theta\notin IC(\boldsymbol{X})\right)=1-P_\theta\left(\theta\in IC(\boldsymbol{X})\right),$$

Pour tout θ de Θ.

5.2.2. Critère d'optimalité

DEFINITION : *Un intervalle de confiance de niveau de confiance $(1-\alpha)$ pour le paramètre inconnu θ, $IC(\boldsymbol{X})$ est dit préférable à un autre intervalle de confiance de même niveau de confiance $IC'(\boldsymbol{X})$, ou plus exact que $IC'(\boldsymbol{X})$ si la probabilité que $IC(\boldsymbol{X})$ recouvre une valeur erronée de θ est inférieure à la probabilité correspondante pour $IC'(\boldsymbol{X})$:*

$$\left(\forall\theta,\theta^*\in\Theta\right),P_\theta\left[\theta^*\in IC(\boldsymbol{X})\right]\leq P_\theta\left[\theta^*\in IC'(\boldsymbol{X})\right]$$

DEFINITION : *Un intervalle de confiance de niveau $(1-\alpha)$ pour θ est dit optimal ou uniformément plus exacte (UPE) au niveau $(1-\alpha)$ pour θ s'il est plus exact que tout autre intervalle de confiance de niveau $(1-\alpha)$ pour θ.*

Il n'existe pas d'intervalles de confiance (règle de décision) optimaux.

5.2.2.2.1. Principe sans biais

Le principe sans biais permet de retenir un intervalle de confiance optimale dans la classe des intervalles de confiance sans biais de niveau de confiance $(1-\alpha)$ pour θ.

DEFINITION : *Un intervalle de confiance de niveau de confiance $(1-\alpha)$ pour θ est dit uniformément le plus exact sans biais (UPESB) au niveau de signification $(1-\alpha)$ pour θ s'il est préférable à tout intervalle de confiance sans biais de niveau $(1-\alpha)$ pour θ.*

5.2.1.2.2. Autres critères

Plus l'intervalle est court et plus la localisation du paramètre inconnu est précise ;

5.3. Construction d'un estimateur par intervalle de confiance : approche fréquentiste

5.3.1. Principes généraux pour construire un intervalle de confiance

Le principe de la fonction pivotale et principe de grands échantillons sont à la base de la construction d'intervalles de confiance selon l'approche fréquetiste.

5.3.1.1. Définition d'une fonction pivotale exacte

DEFINITION : *Une fonction pivotale exacte (ou pivot ou encore variable pivotale) pour le paramètre inconnu θ est toute fonction Ψ définie sur $\mathcal{X}^n\times\Theta$ telle que pour tout $\theta\in\Theta$, la fonction $\boldsymbol{x}\mapsto\psi(\boldsymbol{x},\theta)$ soit mesurable par rapport à la tribu sous-jacente au modèle et dont la loi est connue et indépendante de θ.*

5.3.1.2. Définition d'une fonction pivotale asymptotique

DEFINITION : *Une fonction asymptotiquement pivotale (ou pivot asymptotique) pour θ est toute fonction ψ définie sur $\mathcal{X}^n\times\Theta$ telle que pour tout $\theta\in\Theta$, la fonction $\boldsymbol{x}\mapsto\psi(\boldsymbol{x},\theta)$ soit mesurable par rapport à la tribu sous-jacente au modèle et converge en loi ($n\to+\infty$) vers une loi connue et indépendante de θ.*

5.3.2. Intervalles de confiance pour estimer un paramètre

5.3.2.1. Intervalle de confiance de la moyenne d'un échantillon gaussien

Soit un les données $(x_1,\ldots,x_n)\in\mathcal{X}^n$ de l'observation d'un phénomène aléatoire, modélisées par l'échantillon gaussien,

$$\{X_1,\ldots,X_n\} \sim \mathcal{N}(\theta,\sigma^2)$$

il est question de construire un intervalle de confiance de la moyenne θ au niveau de confiance $(1-\alpha)$.

Les résultats de l'intervalle de confiance de niveau $(1-\alpha)$ de la moyenne inconnue d'un échantillon gaussien lorsque la variance est connue et égale à σ_0^2 sont regroupés dans l'encadré ci-dessous.

Intervalle de confiance exact de niveau $(1-\alpha)$ de la moyenne inconnue θ d'une loi gaussienne lorsque la variance est connue et égale à σ_0^2

- *Bilatéral*

$$IC(\theta)=\bar{X}_n\pm z_{\alpha/2}\cdot\frac{\sigma_0}{\sqrt{n}}=\left[\bar{X}_n-z_{1-\alpha/2}\cdot\frac{\sigma_0}{\sqrt{n}},\bar{X}_n+z_{\alpha/2}\cdot\frac{\sigma_0}{\sqrt{n}}\right]$$

- *Unilatéral à gauche*

$$IC(\theta)=\left]-\infty,\bar{X}_n-z_{\alpha}\cdot\frac{\sigma_0}{\sqrt{n}}\right]$$

- *Unilatéral à droite*

$$IC(\theta)=\left[\bar{X}_n-z_{1-\alpha}\cdot\frac{\sigma_0}{\sqrt{n}},+\infty\right[$$

Intervalle de confiance exact de niveau $(1-\alpha)$ de la moyenne θ d'une loi gaussienne lorsque la variance est inconnue

- *Bilatéral*

$$IC(\theta)=\bar{X}_n\pm t_{(n-1)^{(1-\alpha/2)}}\cdot\frac{s_n}{\sqrt{n}}=\left[\bar{X}_n-t_{(n-1)^{(1-\alpha/2)}}\cdot\frac{s_n}{\sqrt{n}},\bar{X}_n+t_{(n-1)^{(\alpha/2)}}\cdot\frac{s_n}{\sqrt{n}}\right]$$

- *Unilatéral à gauche*

$$IC(\theta)=\left]-\infty,\bar{X}_n-t_{(n-1)^{(\alpha)}}\cdot\frac{s_n}{\sqrt{n}}\right]$$

- *Unilatéral à droite*

$$IC(\theta)=\left[\bar{X}_n-t_{(n-1)^{(1-\alpha)}}\cdot\frac{s_n}{\sqrt{n}},+\infty\right[$$

Exemple d'application

Obame est un éleveur. Il utilisait jusqu'à présent un régime *A* avec lequel les conditions l'élevage de bovins conduisaient à un poids moyen à un âge donné de $310\,\text{kg}$. Un fournisseur lui propose un nouveau régime *B* qu'il teste sur 10 animaux et obtient les résultats consignés dans le tableau suivant :

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
331	316	309	317	320	332	303	300	328	305

Les données sont en kilogrammes (kg) et suivent une loi gaussienne et il est admis qu'elles proviennent d'une loi gaussienne

1. Quel est le phénomène aléatoire étudié par l'éleveur *Obame* ?
2. Quelle est l'observation du phénomène aléatoire étudié ?
3. Est-ce que l'évidence des données permet de soupçonner que le nouveau régime *B* est meilleur que l'ancien régime *A* ?
4. *Obame* a-t-il de bonnes raisons de penser, au niveau de confiance $(1-\alpha)=99\%$, que le nouveau régime *B* est meilleur que l'ancien régime *A* ?

5.3.2.2. Intervalle de confiance de la variance d'un échantillon gaussien

Soit les données $(x_1,\ldots,x_n)\in\mathcal{X}^n$ de l'observation d'un phénomène aléatoire étudié, modélisées par l'échantillon gaussien : $\{X_1,\ldots,X_n\} \sim \mathcal{N}(\mu,\theta)$

il est question de construire un intervalle de confiance de θ au niveau de confiance $(1-\alpha)$.

Les résultats de l'intervalle de confiance de la variance θ d'un échantillon gaussien, la moyenne étant connue et égale à μ_0 ,sont regroupés dans l'encadré ci-dessous.

Intervalle de confiance exact de niveau $(1-\alpha)$ de la variance θ d'une loi gaussienne lorsque la moyenne est connue égale à μ_0

- *Bilatéral*

$$IC(\theta)=\left[\frac{n\hat{\theta}}{\chi^2_{(n)^{(1-\frac{\alpha}{2})}}},\frac{n\hat{\theta}}{\chi^2_{(n)^{(\frac{\alpha}{2})}}}\right]$$

- *Unilatéral à gauche*

$$IC(\theta)=\left]0,\frac{n\hat{\theta}}{\chi^2_{(n)^{(\alpha)}}}\right]$$

- *Unilatéral à droite*

$$IC(\theta)=\left[\frac{n\hat{\theta}}{\chi^2_{(n)^{(1-\alpha)}}},+\infty\right[$$

Intervalle de confiance exact de niveau $(1-\alpha)$ de la variance θ d'une loi gaussienne lorsque la moyenne est inconnue

- *Bilatéral*

$$IC(\theta)=\left[\frac{(n-1)s_n^2}{\chi^2_{(n)^{(1-\frac{\alpha}{2})}}}\ ,\ \frac{(n-1)s_n^2}{\chi^2_{(n)^{(\frac{\alpha}{2})}}}\right]$$

- *Unilatéral à gauche*

$$IC(\theta)=\left]0,\frac{(n-1)s_n^2}{\chi^2_{(n-1)^{(\alpha)}}}\right]$$

- *Unilatéral à droite*

$$IC(\theta)=\left[\frac{(n-1)s_n^2}{\chi^2_{(n-1)^{(1-\alpha)}}},+\infty\right[$$

Exemple d'application

Une entreprise de fabrication de confiseries veut respecter les normes de fabrication concernant le pourcentage de colorant contenu dans ses produits. Pour vérifier si la fabrication est conforme, chaque jour un employé est responsable de prélever un échantillon aléatoire de 9 confiseries et de calculer la variance de l'échantillon. La fabrication sera déclarée non-conforme si la variance du pourcentage de colorant est supérieure à 0.9. Un échantillon de 9 mesures en pourcentages a été prélevé ce jour et les données sont consignées dans le tableau suivant :

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9
2.5	3.0	3.2	3.6	2.0	2.1	1.5	1.2	1.0

Il est admis que ces données proviennent d'une loi gaussienne

1. Quel est le phénomène aléatoire étudié ?
2. Quelle est l'observation du phénomène aléatoire étudié ?
3. Est-que l'évidence des données collectées permet de penser que la fabrication n'est pas conforme ?
4. A-t-on de bonnes raisons de penser, au niveau de confiance 95% que la fabrication n'est pas conforme ?

5.3.2.3. Intervalle de confiance du paramètre d'un échantillon non gaussien

5.3.2.3.1. Intervalle de confiance exact d'une proportion

Soit les données $(x_1,\ldots,x_n)\in\mathcal{X}^n$ de l'observation d'un phénomène aléatoire étudié, il est question de construire un intervalle de confiance exact de niveau de confiance $(1-\alpha)$ pour p. Dans beaucoup de situations pratiques, l'intervalle de confiance est construit avec un pivot asymptotique en utilisant soit le théorème central limite ou encore la propriété des estimateurs du maximum de vraisemblance dans un modèle régulier.

Lorsque $n\geq 30$, alors la fonction pivotale asymptotique pour la proportion p est définie de la manière suivante :

$$\psi(X_1,\ldots,X_n;p)=\frac{\hat{p}-E(\hat{p})}{\sqrt{Var(\hat{p})}}=\frac{\hat{p}-p}{\sqrt{Var(\hat{p})}}$$

Sa loi est une loi normale centrée réduite d'après le théorème central limite :

$$\psi(X_1,\ldots,X_n;p)\ \xrightarrow[n\to+\infty]{\mathcal{L}}\ \mathcal{N}(0,1)$$

La construction de l'intervalle de confiance nécessite de connaître l'estimation de la variance au dénominateur de la fonction pivotale. Plusieurs méthodes sont proposées dans la littérature. Les plus usuelles sont présentées ci-dessous.

Méthode lorsque la variance au dénominateur du pivot est connue

Intervalle de confiance asymptotique d'une proportion p lorsque la variance au dénominateur du pivot est connue

- *Bilatéral*

$$IC(p)=\hat{p}\pm z_{\alpha/2}\cdot Var(\hat{p})=\left[\hat{p}-z_{1-\alpha/2}\cdot Var(\hat{p}),\hat{p}+z_{\alpha/2}\cdot Var(\hat{p})\right]$$

- *Unilatéral à gauche*

$$IC(p)=\left]-\infty,\hat{p}-z_{\alpha}\cdot\sqrt{Var(\hat{p})}\right]$$

- *Unilatéral à droite*

$$IC(p)=\left[\hat{p}-z_{1-\alpha}\cdot\sqrt{Var(\hat{p})},+\infty\right[$$

Méthode standard traditionnelle ou méthode de WALD

La *méthode standard* traditionnelle, nommée *méthode asymptotique* encore appelée *méthode de Wald* utilise le majorant de $p(1-p)$, ou encore l'écart-type de la loi binomiale observée pour estimer la variance qui est au dénominateur du pivot.

Intervalles de confiance de Wald de niveau d'une proportion p
(méthode par excès)

- *Bilatéral*

$$IC(p)=\hat{p}\pm z_{\alpha/2}\cdot\sqrt{\frac{1}{4n}}=\left[\hat{p}-z_{1-\alpha/2}\cdot\sqrt{\frac{1}{4n}},\hat{p}+z_{\alpha/2}\cdot\sqrt{\frac{1}{4n}}\right]$$

- *Unilatéral à gauche*

$$IC(p)=\left]0,\hat{p}-z_{\alpha}\cdot\sqrt{\frac{1}{4n}}\right]$$

- *Unilatéral à droite*

$$IC(p)=\left[\hat{p}-z_{1-\alpha}\cdot\sqrt{\frac{1}{4n}},1\right[$$

Intervalles de confiance de Wald d'une proportion p
(méthode traditionnelle)

- *Bilatéral*

$$IC(p)=\hat{p}\pm z_{\alpha/2}\cdot\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}=\left[\hat{p}-z_{1-\alpha/2}\cdot\sqrt{\frac{\hat{p}(1-\hat{p})}{n}},\hat{p}+z_{\alpha/2}\cdot\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\right]$$

- *Unilatéral à gauche*

$$IC(p)=\left]0,\hat{p}-z_{\alpha}\cdot\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\right]$$

- *Unilatéral à droite*

$$IC(p)=\left[\hat{p}-z_{1-\alpha}\cdot\sqrt{\frac{\hat{p}(1-\hat{p})}{n}},1\right[$$

Méthode de Wilson

La méthode de Wilson (1927) aussi appelée *méthode du score* ou *méthode de l'ellipse*, est basé sur une approximation normale de la loi binomiale.

Intervalles de confiance de Wilson d'une proportion p

- *Bilatéral*

$$IC(p)=\frac{\left(2n\hat{p}+z_{\alpha/2}^2\right)}{2\left(n+z_{\alpha/2}^2\right)}\pm\frac{z_{\alpha/2}\sqrt{4n\hat{p}(1-\hat{p})+z_{\alpha/2}^2}}{2\left(n+z_{\alpha/2}^2\right)}$$

- *Unilatéral à gauche*

$$IC(p)=\left]0,\frac{\left(2n\hat{p}+z_{\alpha/2}^2\right)-z_{\alpha/2}\sqrt{4n\hat{p}(1-\hat{p})+z_{\alpha/2}^2}}{2\left(n+z_{\alpha/2}^2\right)}\right]$$

- *Unilatéral à droite*

$$IC(p)=\left[\frac{\left(2n\hat{p}+z_{\alpha/2}^2\right)+z_{\alpha/2}\sqrt{4n\hat{p}(1-\hat{p})+z_{\alpha/2}^2}}{2\left(n+z_{\alpha/2}^2\right)},1\right[$$

Méthodes de Wald et Wilson avec correction de continuité

Pour tenir compte de l'approximation d'une loi discrète (ici loi binomiale) par une loi continue (ici normale), Yates (1934).

Intervalles de confiance de Wald d'une proportion p avec correction de continuité

- *Bilatéral*

$$IC(p)=\hat{p}\pm z_{\alpha/2}\cdot\left[\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}+\frac{1}{2n}\right]$$

- *Unilatéral à gauche*

$$IC(p)=\left]0,\hat{p}-z_{\alpha}\cdot\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}-\frac{1}{2n}\right]$$

- *Unilatéral à droite*

$$IC(p)=\left[\hat{p}-z_{1-\alpha}\cdot\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}+\frac{1}{2n},1\right[$$

5.3.2.3.2.2. Méthode utilisant les propriétés d'un modèle statistique régulier

Dans un modèle statistique régulier, l'estimateur du maximum de vraisemblance $\hat{p}$ du paramètre inconnu p a la propriété asymptotique suivante :

$$\sqrt{nI_n(p)}(\hat{p}-p)\xrightarrow[n\to+\infty]{\mathcal{L}}\mathcal{N}(0,1)$$

C'est-à-dire :

$$\hat{p}\xrightarrow{\mathcal{L}}\mathcal{N}\left(p,1/I(p)\right)$$

Intervalles de confiance asymptotiques pour θ dans un modèle régulier

- *Bilatéral :* $IC(p) = \hat{p} \pm z_{\alpha/2} \cdot \sqrt{I_n^{-1}(\hat{p})}$
- *Unilatéral à gauche :* $IC(p) = \left]-\infty, \hat{p} - z_{\alpha} \cdot \sqrt{I_n^{-1}(\hat{p})}\right]$
- *Unilatéral à droite :* $IC(p) = \left[\hat{p} - z_{1-\alpha} \cdot \sqrt{I_n^{-1}(\hat{p})}, +\infty\right[$

5.3.3. Intervalles de confiance pour comparer deux échantillons

5.3.3.1. Intervalles de confiance pour comparer deux échantillons indépendants

Soit les données $(x_1,\ldots,x_{n_1}) \in \mathcal{X}^{n_1}$ et $(y_1,\ldots,y_{n_2}) \in \mathcal{X}^{n_2}$, modélisées par deux échantillons gaussiens indépendants $\{X_1,\ldots,X_{n_1}\}$ et $\{Y_1,\ldots,Y_{n_2}\}$, il est question de vérifier au niveau de confiance $(1-\alpha)$ si les variances σ_1^2 et σ_2^2 sont égales ou non.

Intervalles de confiance exacts du rapport des variances de deux échantillons gaussiens : moyennes connues

- *Bilatéral*

$$IC\left(\frac{\sigma_1^2}{\sigma_2^2}\right) = \left[\frac{\hat{\sigma}_{n_1}^2}{\hat{\sigma}_{n_2}^2} \frac{1}{F_{(n_1,n_2)^{(1-\alpha/2)}}}, \frac{\hat{\sigma}_{n_1}^2}{\hat{\sigma}_{n_2}^2} \frac{1}{F_{(n_1,n_2)^{(\alpha/2)}}}\right]$$

- *Unilatéral à gauche*

$$IC\left(\frac{\sigma_1^2}{\sigma_2^2}\right) = \left]0, \frac{\hat{\sigma}_{n_1}^2}{\hat{\sigma}_{n_2}^2} \frac{1}{F_{(n_1-1,n_2-1)^{(\alpha)}}}\right]$$

- *Unilatéral à droite*

$$IC\left(\frac{\sigma_1^2}{\sigma_2^2}\right) = \left[\frac{s_{n_1}^2}{s_{n_2}^2} \frac{1}{F_{(n_1-1,n_2-1)^{(1-\alpha)}}}, +\infty\right[$$

Intervalles de confiance exacts du rapport des variances de deux échantillons gaussiens : moyennes inconnues

- *Bilatéral*

$$IC\left(\frac{\sigma_1^2}{\sigma_2^2}\right) = \left[\frac{s_{n_1}^2}{s_{n_2}^2} \frac{1}{F_{(n_1-1,n_2-1)^{(1-\alpha/2)}}}, \frac{s_{n_1}^2}{s_{n_2}^2} \frac{1}{F_{(n_1-1,n_2-1)^{(\alpha/2)}}}\right]$$

- *Unilatéral à gauche*

$$IC\left(\frac{\sigma_1^2}{\sigma_2^2}\right) = \left]0, \frac{s_{n_1}^2}{s_{n_2}^2} \frac{1}{F_{(n_1-1,n_2-1)^{(\alpha)}}}\right]$$

- *Unilatéral à droite*

$$IC\left(\frac{\sigma_1^2}{\sigma_2^2}\right) = \left[\frac{s_{n_1}^2}{s_{n_2}^2} \frac{1}{F_{(n_1-1,n_2-1)^{(1-\alpha)}}}, +\infty\right[$$

Soit un phénomène aléatoire observé dans deux circonstances différentes, décrites par les variables statistiques gaussiennes X et Y de moyennes respectives θ_1 et θ_2 et de variances σ_1^2 et σ_2^2 : $X \sim \mathcal{N}(\theta_1, \sigma_1^2)$ et $Y \sim \mathcal{N}(\theta_2, \sigma_2^2)$. Il est question de construire un intervalle de confiance sur la différence de θ_1 et θ_2, permettant de dire si ces moyennes sont différentes ou non au niveau de confiance $(1-\alpha)$.

Intervalles de confiance exacts pour comparer les moyennes de deux échantillons gaussiens lorsque les variances sont connues égales

- *Bilatéral*

$$IC(\theta) = \hat{\theta} \pm z_{1-\alpha/2} \cdot \sqrt{\frac{\sigma_{01}^2}{n_1} + \frac{\sigma_{02}^2}{n_2}} = \left(\bar{x}_{n_1} - \bar{y}_{n_2}\right) \pm z_{1-\alpha/2} \cdot \sqrt{\frac{\sigma_{01}^2}{n_1} + \frac{\sigma_{02}^2}{n_2}}$$

- *Unilatéral à gauche*

$$IC(\theta) = \left]-\infty, \hat{\theta} - z_{\alpha} \cdot \sqrt{\frac{\sigma_{01}^2}{n_1} + \frac{\sigma_{02}^2}{n_2}}\right] = \left]-\infty, \left(\bar{x}_{n_1} - \bar{y}_{n_2}\right) - z_{\alpha} \cdot \sqrt{\frac{\sigma_{01}^2}{n_1} + \frac{\sigma_{02}^2}{n_2}}\right]$$

- *Unilatéral à droite*

$$IC(\theta) = \left[\hat{\theta} - z_{1-\alpha} \cdot \sqrt{\frac{\sigma_{01}^2}{n_1} + \frac{\sigma_{02}^2}{n_2}}, +\infty\right[= \left[\left(\bar{x}_{n_1} - \bar{y}_{n_2}\right) - z_{1-\alpha} \cdot \sqrt{\frac{\sigma_{01}^2}{n_1} + \frac{\sigma_{02}^2}{n_2}}, +\infty\right[$$

Intervalles de confiance exacts de la différence des moyennes de deux échantillons gaussiens indépendants lorsque les variances sont inconnues et homoscédastiques

- *Bilatéral*

$$IC(\theta) = \left(\bar{x}_{n_1} - \bar{y}_{n_2}\right) \pm t_{(n_1+n_2-2)^{(\alpha/2)}} \cdot s_n \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}$$

- *Unilatéral à gauche*

$$IC(\theta) = \left]-\infty, \left(\bar{x}_{n_1} - \bar{y}_{n_2}\right) - t_{(n_1+n_2-2)^{(\alpha)}} \cdot s_n \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}\right]$$

- *Unilatéral à droite*

$$IC(\theta) = \left[\left(\bar{x}_{n_1} - \bar{y}_{n_2}\right) - t_{(n_1+n_2-2)^{(1-\alpha)}} \cdot s_n \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}, +\infty\right[$$

Intervalles de confiance exacts de la différence des moyennes de deux échantillons gaussiens indépendants lorsque les variances sont inconnues et hétéroscédastiques

- *Bilatéral*

$$IC(\theta)=\left(\bar{x}_{n_1}-\bar{y}_{n_2}\right)\pm t_{(\nu)}{}^{(\alpha/2)}\cdot\sqrt{\left(\frac{s_{n_1}^2}{n_1}+\frac{s_{n_2}^2}{n_2}\right)}$$

- *Unilatéral à gauche*

$$IC(\theta)=\left]-\infty,\left(\bar{x}_{n_1}-\bar{y}_{n_2}\right)-t_{(\nu)}{}^{(\alpha)}\cdot\sqrt{\left(\frac{s_{n_1}^2}{n_1}+\frac{s_{n_2}^2}{n_2}\right)}\right]$$

- *Unilatéral à droite*

$$IC(\theta)=\left[\left(\bar{x}_{n_1}-\bar{y}_{n_2}\right)-t_{(\nu)}{}^{(1-\alpha)}\cdot\sqrt{\left(\frac{s_{n_1}^2}{n_1}+\frac{s_{n_2}^2}{n_2}\right)},+\infty\right[$$

Exemple d'application

À l'hôpital de District de Deido à Douala au Cameroun, une étude cherche à vérifier si l'âge moyen d'apparition de la maladie cardiaque est le même chez les hommes et chez les femmes. Pour ce faire, l'âge d'apparition de la maladie a été observé aléatoirement sur 10 hommes et 8 femmes. Les données obtenues sont rangées dans le tableau suivant :

Homme	19	26	31	25	18	22	25	27	17	20
Femme	33	29	26	21	20	23	24	31		

Il est admis que ces données proviennent de populations gaussiennes

1. Quelle est l'observation du phénomène étudié ?
2. Est-ce que ces données soutiennent l'égalité des deux variances au niveau de confiance 95%.
3. Est-ce que ces données permettent de soutenir, au niveau de confiance 95%, que l'âge moyen d'apparition de la maladie cardiaque est le même chez les hommes et chez les femmes ?

Soit un phénomène aléatoire étudié dans deux circonstances différentes, décrites par des variables statistiques de Bernoulli X et Y, prenant chacune deux modalités dont l'une est noté A et la probabilité d'observer A est respectivement notée p_1 et p_2 : $X \sim \mathcal{B}er(p_1)$ et $Y \sim \mathcal{B}er(p_2)$. Il est question de construire un intervalle de confiance de la différence de p_1 et p_2, permettant de dire au niveau de confiance $(1-\alpha)$ si ces deux proportions sont égales ou non.

Intervalles de confiance approchés de la différence de proportions dans deux échantillons indépendants (*méthode par excès*)

- *Bilatéral*

$$IC(p)=[a,b]=\hat{p}\pm z_{1-\alpha/2}\cdot\sqrt{\frac{1}{4}\left(\frac{1}{n_1}+\frac{1}{n_2}\right)}$$

- *Unilatéral à gauche*

$$IC(p)=\left]-1\quad,\quad\hat{p}-z_{\alpha}\cdot\sqrt{\frac{1}{4}\left(\frac{1}{n_1}+\frac{1}{n_2}\right)}\right]$$

- *Unilatéral à droite*

$$IC(p)=\left[\hat{p}-z_{1-\alpha}\cdot\sqrt{\frac{1}{4}\left(\frac{1}{n_1}+\frac{1}{n_2}\right)}\quad,\quad 1\right[$$

Intervalle de confiance pour comparer les proportions de deux échantillons indépendants de grandes tailles (*méthode courante*)

- *Bilatéral*

$$IC(p)=\hat{p}\pm z_{1-\alpha/2}\cdot\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1}+\frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$$

- *Unilatéral à gauche*

$$IC(p)=\left]-1\quad,\quad\hat{p}+z_{\alpha}\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1}+\frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}\right]$$

- *Unilatéral à droite*

$$IC(p)=\left[\hat{p}-z_{1-\alpha}\cdot\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1}+\frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}\quad,\quad 1\right[$$

Exemple d'application

Lors d'un test de qualité sur deux publicités (A et B) télévisées et diffusées à la Radiodiffusion-télévision du *Cameroun* (CRTV), chaque publicité a été diffusée six fois au cours d'une semaine. La semaine suivante, une enquête téléphonique a été effectuée pour identifier les personnes qui avaient vu les publicités. La question posée à l'enquêtés était la suivante : "*avez-vous vu la publicité* ?" S'il répondait par l'affirmative, la question subsidiaire était : " *décrivez le slogan principal de la publicité*". Les résultats obtenus sont regroupés dans le tableau ci-dessous.

Publicité	Nombre de personnes	
	qui ont vu la publicité	*qui se souviennent du slogan*
A	150	63
B	200	60

1. Quel est le phénomène aléatoire étudié ?
2. Quelle est l'observation du phénomène étudié ?
3. Est-ce que l'évidence des données permet de soupçonner que la publicité A est mieux perçue que la publicité B ?
4. Est-ce que les données permettent de conclure au niveau de confiance 95% que la publicité A est mieux perçue que la publicité B ?

Soit un phénomène aléatoire étudié dans deux situations différentes, décrites par des variables statistiques X et Y de moyennes respectives θ_1 et θ_2 et de variances σ_1^2 et σ_2^2. Il est question de construire un intervalle de confiance sur la différence de θ_1 et θ_2, permettant de vérifier si ces deux moyennes sont égales ou non au niveau de confiance $(1-\alpha)$.

Intervalles de confiance approchés de la différence de deux moyennes de deux échantillons indépendants

- *Bilatéral*

$$IC(\theta)=\hat{\theta}\pm z_{1-\alpha/2}\cdot\sqrt{\frac{\hat{\sigma}_1^2}{n_1}+\frac{\hat{\sigma}_2^2}{n_2}}=\left(\bar{x}_{n_1}-\bar{y}_{n_2}\right)\pm z_{1-\alpha/2}\cdot\sqrt{\frac{\hat{\sigma}_1^2}{n_1}+\frac{\hat{\sigma}_2^2}{n_2}}$$

- *Unilatéral à gauche*

$$IC(\theta)=\left]-\infty,\hat{\theta}-z_{\alpha}\cdot\sqrt{\frac{\hat{\sigma}_1^2}{n_1}+\frac{\hat{\sigma}_2^2}{n_2}}\right]=\left]-\infty,\left(\bar{x}_{n_1}-\bar{y}_{n_2}\right)-z_{\alpha}\cdot\sqrt{\frac{\hat{\sigma}_1^2}{n_1}+\frac{\hat{\sigma}_2^2}{n_2}}\right]$$

- *Unilatéral à droite*

$$IC(\theta)=\left[\hat{\theta}-z_{1-\alpha}\cdot\sqrt{\frac{\hat{\sigma}_1^2}{n_1}+\frac{\hat{\sigma}_2^2}{n_2}},+\infty\right[=\left[\left(\bar{x}_{n_1}-\bar{y}_{n_2}\right)-z_{1-\alpha}\cdot\sqrt{\frac{\hat{\sigma}_1^2}{n_1}+\frac{\hat{\sigma}_2^2}{n_2}},+\infty\right[$$

5.3.3.2. Intervalles de confiance pour comparer deux échantillons appariés

Soit un phénomène aléatoire observé dans deux situations différentes décrites par les variables aléatoires gaussiennes X et Y de moyenne et variance respectives θ_1 et θ_2 et σ_1^2 et σ_2^2 : $X\sim\mathcal{N}\left(\theta_1,\sigma_1^2\right)$ et $Y\sim\mathcal{N}\left(\theta_2,\sigma_2^2\right)$. Il est question de construire un intervalle de confiance sur la différence de θ_1 et θ_2, permettant de dire si ces deux moyennes sont égales ou non au niveau de confiance $(1-\alpha)$.

Intervalle de confiance exact de la différence des moyennes de deux échantillons gaussiens appariés

- *Bilatéral*

$$IC(\theta_d)=\bar{d}_n\pm t_{(n-1)(1-\alpha/2)}\cdot\frac{s_d}{\sqrt{n}}=\left[\bar{d}_n-t_{(n-1)(1-\alpha/2)}\cdot\frac{s_d}{\sqrt{n}},\bar{d}_n+t_{(n-1)(\alpha/2)}\cdot\frac{s_d}{\sqrt{n}}\right]$$

- *Unilatéral à gauche*

$$IC(\theta)=\left]-\infty,\bar{d}_n-t_{(n-1)(\alpha)}\cdot\frac{s_d}{\sqrt{n}}\right]$$

- *Unilatéral à droite*

$$IC(\theta)=\left[\bar{d}_n-t_{(n-1)(1-\alpha)}\cdot\frac{s_d}{\sqrt{n}},+\infty\right[$$

Exemple d'application

Dans le cadre d'un programme visant à réduire le tabagisme en République Centrafricaine, une Organisation Non Gouvernementale installée à Bangui a mené une campagne publicitaire pour convaincre les gens d'arrêter de fumer ou de réduire leur consommation de tabac. Afin d'évaluer l'efficacité de leur campagne, les responsables ont demandé à 12 sujets de noter le nombre moyen de cigarettes fumées par jour durant la semaine précédant et la semaine qui a suivi la campagne. Les données collectées sont les suivantes :

Sujet	1	2	3	4	5	6	7	8	9	10	11	12
Avant	45	16	20	33	30	19	33	25	26	40	28	36
Après	43	20	17	30	25	19	34	28	23	41	26	40

Il est admis que ces données proviennent de lois gaussiennes

1. Quel est le phénomène aléatoire étudié ?
2. Quelle est l'observation du phénomène aléatoire étudié ?
3. Est-ce que ces données permettent de soutenir au niveau de confiance $(1-\alpha)=95\%$ que la campagne publicitaire a eu un effet sur la consommation de cigarettes en République Centrafricaine ?

5.4. Méthode bayésienne de construction d'un estimateur par intervalle de confiance

L'approche bayésienne parle d'intervalle de crédibilité plutôt que d'intervalle de confiance. Le calcul de cet intervalle est trivial dès lors que la loi *a posteriori* est déterminée, en utilisant les quantiles de cette dernière.

5.4.1. Région de crédibilité

DEFINITION : *Soient* $\left[\mathcal{X}, \wp = \{P_\theta, \theta \in \Theta\}\right]$ *un modèle statistique pour étudier un phénomène aléatoire décrit par une variable statistique* X *de loi* $P_X = P_\theta$, $\{X_1, \ldots, X_n\}$ *un échantillon théorique de loi* P_θ, $\{x_1, \ldots, x_n\}$ *sa réalisation,* π *la loi a priori du paramètre inconnu* θ, $\pi(\theta/\boldsymbol{x})$ *la loi a posteriori de* θ *et un réel* α *fixé compris dans l'intervalle* $]0,1[$. *Une région de crédibilité* $C \subset \Theta$ *de niveau (au moins)* $(1-\alpha)$ *de* $\pi(\theta/\boldsymbol{x})$, *ou région* $\alpha-$*crédible pour* θ *est un ensemble* $C = C(\boldsymbol{X})$ *tel que :*

$$P(\theta \in C(\boldsymbol{X})) = 1-\alpha$$

où, P *est la probabilité dont la densité a posteriori est* $\pi(\theta/\boldsymbol{x})$.

5.4.2. Démarche pour construire un intervalle de crédibilité

DEFINITION : *Soient* $\left[\mathcal{X}, \wp = \{P_\theta, \theta \in \Theta\}\right]$ *un modèle statistique pour étudier un phénomène aléatoire décrit par une variable statistique* X *de loi* $P_X = P_\theta$, $\{X_1, \ldots, X_n\}$ *un échantillon théorique de loi* P_θ, $\{x_1, \ldots, x_n\}$ *sa réalisation,* π *la loi a priori du paramètre inconnu* θ, $\pi(\theta/\boldsymbol{x})$ *la loi a posteriori de* θ *et un réel* α *compris dans l'intervalle* $]0,1[$. *Une région de crédibilité est dite de volume minimal si elle s'écrit :*

$$C(\boldsymbol{x}) = \{\theta / \pi(\theta/x) \geq k_\alpha\}$$

où, k_α *est la plus grande valeur telle que :*

$$P(\theta \in C(\boldsymbol{X})) = 1-\alpha$$

P *est la probabilité dont la densité a posteriori est* $\pi(\theta/\boldsymbol{x})$

5.4.3. Exemple d'application

Une entreprise de fabrication de confiseries veut respecter les normes de fabrication concernant le pourcentage de colorant contenu dans ses produits. Pour vérifier si la fabrication est conforme, chaque jour un employé est responsable de prélever un échantillon aléatoire de 9 confiseries et le poids moyen de l'échantillon est calculé. La fabrication est déclarée non-conforme si la moyenne du pourcentage de colorant est supérieure à 2. Un échantillon de 9 mesures en pourcentages a été prélevé et les données obtenues sont regroupées dans le tableau suivant :

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9
2.5	3.0	3.2	3.6	2.0	2.1	1.5	1.2	1.0

Il est admis que ces données proviennent d'une loi gaussienne $\mathcal{N}(\theta,1)$ et que la loi *a priori* de θ est une gaussienne $\mathcal{N}(2.2,1)$

1. Quel est le phénomène aléatoire étudié ?
2. Quelle est l'observation du phénomène aléatoire étudié ?
3. A-t-on de bonnes raisons de penser, au niveau de confiance $(1-\alpha) = 95\%$, que la fabrication est bien conforme ?